

LAPORAN DAN ANALISIS MACHINE LEARNING
CH 3 BOOK INTRODUCTION TO MACHINE LEARNING WITH PYTHON :
UNSUPERVISED LEARNING



Nama: Robi Septian Subhan
NPM: G1A023060
Mata Kuliah: Machine Learning
Kelas: A, Informatika

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026


1. Pengantar

Laporan ini disusun untuk memberikan pembahasan, analisis dan ringkasan terkait serangkaian eksperimen dari buku *Introduction to Machine Learning with Python*, khususnya pada Bab 3 yang membahas mengenai Unsupervised Learning dan Preprocessing. Pembelajaran tak terawasi (unsupervised learning) merupakan suatu pendekatan dalam pembelajaran mesin yang beroperasi pada kumpulan data yang sama sekali tidak memiliki label, di mana algoritma dituntut untuk mengekstraksi struktur tersembunyi, mencari pola-pola yang bermakna, atau membangun representasi baru dari data tersebut secara mandiri. Analisis dalam laporan ini difokuskan pada tiga ranah utama: pertama, teknik prapemrosesan dan penskalaan data yang seringkali menjadi prasyarat krusial sebelum data diumpankan ke dalam model prediktif. Kedua, teknik reduksi dimensi seperti Principal Component Analysis (PCA), Non-negative Matrix Factorization (NMF), dan t-SNE yang berfungsi menyederhanakan data kompleks agar lebih mudah diinterpretasikan. Ketiga, implementasi algoritma clustering yang mencakup K-Means, Agglomerative, dan DBSCAN beserta cara mengevaluasi keandalannya. Seluruh eksperimen ini dieksekusi menggunakan beberapa dataset standar seperti Breast Cancer Wisconsin, Labeled Faces in the Wild (LFW), handwritten digits, dan data buatan (sintetis).

2. Prapemrosesan dan Penskalaan Data (Scaling)

2.1 Penggunaan MinMaxScaler pada Data Breast Cancer

Prapemrosesan data memegang peranan yang sangat penting sebelum membangun sebuah model pembelajaran mesin. Dalam eksperimen ini, dataset Breast Cancer dibagi menjadi dua bagian utama, yakni 426 sampel yang digunakan untuk proses pelatihan (training set) dan 143 sampel untuk tahap pengujian (test set), dengan setiap observasi memiliki 30 fitur yang berbeda. Saat metode MinMaxScaler diaplikasikan (di-fit) secara eksklusif pada data latih, algoritma ini sukses menormalisasi seluruh fitur hingga berada tepat pada rentang nilai $[0, 1]$. Namun, fenomena menarik terjadi ketika scaler yang telah dilatih tersebut diimplementasikan ke data uji; rentang nilainya tidak lagi sempurna di antara 0 dan 1, melainkan terdapat beberapa fitur yang nilainya melebihi 1 ataupun bernilai negatif. Hal ini bukanlah sebuah kesalahan (error), melainkan prosedur standar yang sangat diharapkan dalam machine learning untuk memastikan tidak ada informasi dari data uji yang bocor (data leakage) ke dalam model selama fase pelatihan.



Gambar 1. Ilustrasi perbedaan berbagai metode penskalaan data terhadap distribusi titik data.


2.2 Pengaruh Penskalaan terhadap Performa SVM

Untuk mengukur seberapa esensial proses penskalaan terhadap performa model algoritmik, sebuah model Support Vector Machine (SVC dengan parameter $C=100$) diuji pada dataset kanker payudara melalui tiga skenario pemrosesan yang berbeda. Pada skenario pertama yang menggunakan data mentah tanpa penskalaan apa pun, model hanya mampu mencapai tingkat akurasi sebesar 0.94 pada test set. Saat data diproses menggunakan MinMaxScaler (menjadi rentang 0 hingga 1), akurasi model melonjak secara drastis menyentuh angka 0.97. Di sisi lain, penggunaan StandardScaler yang menormalisasi data agar memiliki mean 0 dan variansi 1 memberikan hasil akurasi sebesar 0.96. Peningkatan performa yang signifikan ini membuktikan bahwa algoritma SVM sangat sensitif terhadap skala fitur; jika fitur dibiarkan dalam rentang aslinya yang besar, mereka akan mendominasi metrik perhitungan jarak dan mengaburkan pola fitur lain yang memiliki rentang lebih kecil.

3. Analisis Komponen Utama (PCA)

3.1 Reduksi Dimensi pada Dataset *Breast Cancer*

Teknik *Principal Component Analysis* (PCA) dimanfaatkan secara ekstensif untuk mereduksi kompleksitas data tanpa banyak kehilangan informasi yang krusial. Setelah dataset Breast Cancer distandarisasi melalui *StandardScaler*, PCA diterapkan untuk mereduksi 30 fitur asli yang ada menjadi hanya 2 komponen utama saja, yang secara efektif mengubah dimensi matriks dari (569, 30) menjadi (569, 2).



Gambar 2. Distribusi histogram fitur pada dataset Breast Cancer sebelum dilakukan reduksi dimensi PCA.

Melalui visualisasi proyeksi dua dimensi dari ruang baru ini, dapat diamati bahwa kelas *malignant* (ganas) dan *benign* (jinak) dapat dipisahkan dengan garis batas yang relatif jelas, walaupun masih ditemukan sedikit area yang saling tumpang tindih di bagian tengah plot. Jika menilik pada visualisasi *heatmap* koefisien komponen, komponen utama pertama sejatinya adalah agregasi dari hampir keseluruhan fitur dengan arah bobot yang seragam, yang mengindikasikan ukuran atau tingkat keganasan tumor secara holistik. Sementara itu, komponen utama kedua tampak bekerja secara lebih detail dengan membedakan karakteristik spesifik seperti tekstur dan anomali bentuk sel.

3.2 Pengaplikasian PCA pada Citra Wajah (LFW)

Dataset Labeled Faces in the Wild (LFW) memberikan tantangan tersendiri karena memuat 3.023 gambar wajah berdimensi tinggi yang merepresentasikan 62 individu yang berbeda.



Gambar 3. Contoh sampel citra wajah dari dataset Labeled Faces in the Wild (LFW).

Dalam pengujian awal (*baseline*), klasifikasi langsung menggunakan metode 1-Nearest Neighbor pada nilai piksel mentah gambar tersebut hanya sanggup menghasilkan akurasi di angka 22%. Meskipun angka tersebut secara statistik lebih baik daripada tebakan acak, hasilnya masih jauh dari kata memadai karena data piksel secara inheren tidak terlalu informatif untuk klasifikasi identitas. Dengan mengaplikasikan teknik reduksi dimensi PCA *whitening*, akurasi klasifikasi berhasil didorong naik menjadi 30%. Kenaikan ini mengonfirmasi bahwa PCA sangat membantu mengekstrak fitur-fitur esensial (seperti struktur dominan wajah) sambil mereduksi *noise* atau dimensi berlebih yang sering kali

memperburuk performa model. Lebih jauh lagi, proses rekonstruksi gambar membuktikan bahwa penambahan jumlah komponen PCA secara proporsional akan menghasilkan citra yang semakin kaya akan detail dan makin mendekati gambar aslinya.

4. Faktorisasi Matriks Non-Negatif (NMF)

Pendekatan *Non-negative Matrix Factorization* (NMF) menawarkan cara kerja yang secara fundamental berbeda dibandingkan dengan PCA. Jika PCA memungkinkan komponen ortogonal yang dapat bernilai negatif, NMF secara ketat mensyaratkan bahwa seluruh data dan komponennya harus bersifat non-negatif (hanya memiliki nilai positif atau nol). Karakteristik ini memaksa NMF untuk merepresentasikan data secara aditif, yang membuatnya sangat rasional saat digunakan untuk memetakan bagian-bagian fisik penyusun sebuah wajah.

Dalam eksperimen pemisahan sinyal campuran (*signal unmixing*), di mana tiga sinyal sumber disatukan secara sintesis menjadi 100 sinyal pengukuran yang berbeda, NMF membuktikan keunggulannya. Algoritma NMF sukses merekonstruksi kembali bentuk ketiga sinyal asal tersebut dengan sangat presisi, sementara PCA gagal melakukan tugas yang sama karena algoritma tersebut hanya dirancang untuk melacak arah varians maksimum tanpa memperhatikan sifat aditif dari sinyal.

$$\text{Image} \approx X_0 * \text{Feature}_0 + X_1 * \text{Feature}_1 + X_2 * \text{Feature}_2 + X_3 * \text{Feature}_3 + \dots$$

Gambar 4. Perbandingan NMF dan PCA dalam memisahkan dan merekonstruksi sinyal campuran.

5. Pembelajaran Manifold dengan Algoritma t-SNE

Evaluasi pada dataset *handwritten digits* (angka tulisan tangan) memperlihatkan kontras performa yang sangat tajam antara PCA dan t-SNE. Saat menggunakan PCA untuk memproyeksikan data ke ruang 2D, hasil plotnya memperlihatkan distribusi kelas angka yang masih menumpuk menjadi satu, sehingga sulit untuk membedakan antara satu digit dengan digit lainnya.




Gambar 5. Proyeksi PCA pada dataset digits yang memperlihatkan kelas-kelas masih saling tumpang tindih.

Sebaliknya, teknik *manifold learning* yang dimiliki oleh algoritma t-SNE mampu memetakan struktur lokal data dari ruang berdimensi tinggi dengan sangat luar biasa. Visualisasi plot dari t-SNE menghasilkan pemisahan kelas digit yang sangat tegas dan rapi, di mana setiap angka membentuk klaster yang solid dan terisolasi dari kelompok angka lainnya. Kendati demikian, pengguna harus menyadari bahwa t-SNE merupakan alat yang difokuskan murni untuk visualisasi data, karena algoritma ini tidak dibekali dengan fungsi `transform()` dan karenanya tidak dapat memetakan sekumpulan titik data baru tanpa harus dikomputasi ulang dari awal bersama seluruh data latihnya.

6. Implementasi Algoritma *Clustering*

Clustering atau pengelompokan data menghadirkan dinamika yang menarik tergantung pada karakteristik algoritma yang digunakan. Algoritma K-Means terbukti bekerja sangat andal dan presisi ketika dihadapkan pada sekumpulan data sintetis yang telah terpisah dengan batas ruang yang jelas (*well-separated*). Namun, algoritma ini menemui jalan buntu saat mencoba mengelompokkan data yang variansnya tidak seimbang, berbentuk memanjang, atau memiliki distribusi spasial non-konveks layaknya dataset *two-moons*. K-Means secara paksa akan tetap membelah klaster secara membulat karena ia hanya mendasarkan keputusannya pada jarak Euclidean ke titik pusat (*centroid*).




Gambar 6. Keterbatasan algoritma K-Means yang gagal memisahkan data dengan pola non-konveks (*two-moons*).

Di sisi lain, metode *Agglomerative Clustering* yang menggunakan *ward linkage* memperlihatkan hasil partisi yang secara prinsip mirip dengan K-Means, dengan keunggulan tambahan berupa visualisasi *dendrogram* yang sangat membantu analisis visual untuk memprediksi jumlah klaster yang optimal.



Gambar 7. Ilustrasi tahapan penggabungan titik data pada agglomerative clustering.

Pendekatan paling unik ditawarkan oleh DBSCAN yang beroperasi berdasarkan tingkat kepadatan titik data (*density-based*). Meski DBSCAN luar biasa sensitif dan bisa saja mencap seluruh data sebagai *noise* jika parameter *eps* dan *min_samples* miliknya tidak diatur secara cermat, algoritma ini menjadi satu-satunya yang sukses mengidentifikasi dua lengkungan bulan sabit pada dataset *two-moons* tanpa terganggu oleh bentuknya yang non-konveks.



Gambar 8. Pengaruh perubahan parameter eps dan min_samples terhadap hasil cluster dan jumlah noise pada DBSCAN.


7. Pengukuran Performa *Clustering*

Dalam domain pembelajaran tak terawasi, penggunaan metrik akurasi tradisional seringkali menyesatkan karena identitas label dalam *clustering* bersifat arbitrer (penamaan klaster tidak memiliki makna pasti). Eksperimen ini memvalidasi pentingnya menggunakan metrik khusus seperti Adjusted Rand Index (ARI) atau Silhouette Score. ARI secara konsisten mengungguli akurasi konvensional karena metrik ini murni mengevaluasi kesamaan struktur pengelompokan dari suatu model. Walaupun penamaan atau urutan nomor klaster sebuah model tertukar sepenuhnya (yang akan membuat skor akurasinya jatuh menjadi 0.00), ARI tetap akan memberikan nilai 1.00 asalkan titik-titik data tersebut berkumpul dalam grup yang sama. Hal ini dibuktikan pada dataset *two-moons*, di mana DBSCAN memborong nilai ARI paling maksimal karena keberhasilannya memetakan struktur lengkung, berbanding terbalik dengan K-Means yang mendapatkan skor ARI rendah karena membelah lengkungan tersebut.

8. Ekstraksi Fitur Wajah (LFW) dengan Teknik *Clustering*

Mengelompokkan data berdimensi tinggi seperti citra wajah LFW memaksa setiap algoritma *clustering* untuk bekerja hingga batas kemampuannya. Penggunaan DBSCAN terbukti paling tidak ideal untuk skenario ini; variasi kepadatan piksel dan sudut wajah yang luar biasa kompleks membuat pengaturan parameter eps menjadi tugas yang nyaris mustahil diselesaikan dengan baik, dan sebagian besar gambar akhirnya diklasifikasikan sebagai *noise* atau bergabung menjadi satu klaster raksasa. Sementara itu, algoritma K-Means (dengan $k=10$) lebih berhasil mendistribusikan gambar secara merata ke dalam berbagai klaster. Akan tetapi, K-Means lebih berorientasi pada pencarian nilai rata-rata (*mean*) sehingga kelompok yang terbentuk lebih didominasi oleh

kesamaan atribut visual secara umum—seperti pencahayaan atau pose wajah—daripada identitas individu itu sendiri.



Gambar 9. Contoh anggota citra wajah yang dimasukkan ke dalam cluster yang sama oleh algoritma K-Means.

Terakhir, *Agglomerative Clustering* awalnya terlihat memburuk pada $k=10$ karena menciptakan distribusi klaster yang sangat timpang (mencatatkan skor keselarasan ARI yang sangat rendah dengan K-Means, yakni 0.08). Namun, ketika tingkat granularitas klaster diperbesar menjadi $k=40$, *Agglomerative Clustering* mulai memperlihatkan kemampuannya yang terpendam dengan mengelompokkan wajah-wajah dari individu yang sama secara jauh lebih konsisten.

9. Kesimpulan

Dari ragam eksperimen komprehensif yang telah dipaparkan, kita dapat menyarikan enam poin kesimpulan analitis utama:

- a. Fase prapemrosesan melalui *scaling* fitur (seperti `MinMaxScaler` atau `StandardScaler`) bukanlah sebuah opsi opsional, melainkan langkah krusial untuk algoritma berbasis jarak

seperti SVM, yang terbukti mendongkrak kemampuan klasifikasi dari 94% ke angka kompetitif 96-97% pada data medis.

- b. *Principal Component Analysis* (PCA) merupakan instrumen matematis yang sangat tajam untuk mereduksi redundansi data serta membantu visualisasi ruang berdimensi tinggi, walau impaknya terhadap lonjakan performa klasifikasi tetap harus divalidasi berdasarkan distribusi intrinsik data itu sendiri.
- c. Dalam skenario spesifik yang menuntut interpretasi aditif dan nilai non-negatif—misalnya ketika membedah pola struktur wajah atau menjernihkan sinyal audio gabungan—algoritma NMF jauh lebih superior dan relevan jika disandingkan dengan PCA.
- d. Ketika tujuan utamanya adalah pemetaan struktur *manifold* dimensi tinggi ke dalam plot visual dua dimensi, t-SNE membuktikan dirinya jauh lebih efektif dalam memberikan isolasi visual per kelas yang solid, dengan catatan algoritma ini tidak bisa mentransformasi *test set* baru secara seketika.
- e. Setiap metode pengelompokan memiliki keunggulan spesifik: K-Means dan *Agglomerative* sangat ideal untuk pola data yang simetris, berdekatan, atau berbentuk sferis. Sebagai kontras, DBSCAN memonopoli keunggulan pada pencarian pola kompleks dan melengkung, dengan bayaran kompleksitas pencarian parameter yang cukup sensitif.
- f. Pada tahap evaluasi keberhasilan model *clustering*, penggunaan alat ukur yang kebal terhadap permutasi indeks label—khususnya *Adjusted Rand Index* (ARI)—merupakan sebuah kewajiban mutlak untuk memastikan penilaian yang murni berdasarkan relasi struktural antar titik data.